深度学习与自然语言处理作业 4 报告

段沛东 ZY2303106 19231209@buaa.edu.cn

摘要

本文为深度学习与自然语言处理课程第四次作业的报告。本实验采用了 Seq2Seq 和 Transformer 两种深度学习模型进行文本生成任务,并且对比了两种模型的性能差异和优缺点。

问题描述

本实验的主要任务为利用给定语料库(金庸小说语料),用 Seq2Seq 与 Transformer 两种不同的模型来实现文本生成的任务(给定开头后生成武侠小说的片段或者章节),并对比与讨论两种方法的优缺点。

模型原理和实现

Seq2Seq 是常见的文本生成模型,由 Cho 等人在 2014 年首次提出,它主要由 Encoder 和 Decoder 两部分组成,在 Seq2Seq 中两者通常都是循环神经网络(RNN)。Encoder 读取输入文本,并将其压缩成一个固定维度的编码,Decoder 读取 Encoder 生成的编码,并根据这个编码逐步生成目标文本。Seq2Seq 模型通过端到端的训练方式,将输入序列和目标序列直接关联起来,避免了传统方法中繁琐的特征工程和手工设计的对齐步骤。这使得模型能够自动学习从输入到输出的映射关系,提高了序列转换任务的性能和效率。

本实验采用了最简单的 Seq2Seq 模型 Char-RNN,以两个长短期记忆网络(LSTM)分别作为 Encoder 和 Decoder,每次输入一个句子,输出该句子的下一个词,并将生成的词添加到输入句子的末尾,循环生成一个文本段落。

Transformer 是谷歌在 2018 年提出的处理序列输入序列输出问题的模型,Transformer 也采用了 Encoder-Decoder 的架构,但其 Encoder 和 Decoder 都是由数个多头注意力层和前 馈网络组成,而非 Seq2Seq 的循环神经网络,与 Seq2Seq 相比,Transformer 解决了循环神经网络固有的难以克服的缺点,如学习长距离依赖关系的能力差、无法并行计算等,由于解决了无法并行计算的问题,Transformer 架构可以采用参数量极大的模型,在数据和算力充足的情况下,是目前表现最好的文本生成模型。

由于算力和数据都比较有限,本实验实现的 Transformer 的 Encoder 和 Decoder 中堆叠的层数都是 2 层而非原论文中的 6 层。

实验结果

我采用了《射雕英雄传》中的句子作为语料数据集,除去停用词和标点符号并且分词后每 30 词组成一个句子作为训练数据,Seq2Seq 中每个数据对应的标签为该句的下一个词,Transformer 中每个数据对应的标签为该句的下一个句子,分别训练并随机抽选一段 30 词的

段落生成后续100个词的段落。

Seq2Seq 模型进行文本生成的结果如下:

起始句: 奴才不打紧中国百姓可不是跟着成奴才砰郭啸天桌上重重拍一记震倒一只酒杯酒水流满桌怒道不要脸不要脸这鸟皇帝算是一门子皇帝张。

生成结果:十五道全国军民听到讯息无不愤慨之极淮水以北百姓眼见河山恢复无望更是伤心泣血高宗宝座坐得稳若泰山秦桧大功秦桧本来封到鲁国公加封太师荣宠无比权势熏天高宗传孝宗孝宗传光宗金人占定大半江山光宗传到当今天子庆元皇帝手里临安坐五年龙廷这位韩胄韩宰相今后日子难说难说连连摇头郭啸天难说乡下地方尽说无妨临安城里怕惹祸韩胄贼宰相大大的奸臣祸国殃民本事秦桧拜把子兄弟张十五眼前事胆小不敢直言无忌喝杯酒叨扰两位。

Transformer 模型进行文本生成的结果如下:

起始句: 更招架之功北方我国义民到处起兵抄鞑子后路金正在手忙脚乱魂不附体当儿忽然高宗送到降表要求金人皇帝自然大喜若狂议和倒先得杀岳飞。

生成结果:秦桧定下奸计风波亭害死岳爷爷绍兴十一年十二月议和成功宋金两国以淮水中流为界高宗皇帝向金国称臣这道降表是怎生书写杨铁心那定写不要脸张十五道可不是这道降表倒记得高宗皇帝名叫赵构降表中写道臣构言蒙恩造许备藩国世世子孙谨守臣节每年皇帝生辰正旦遣使称贺不绝岁贡银二十五万两绢二十五万匹做奴才不打紧世世子孙做金国皇帝奴才做奴才不打紧中国百姓可不是跟着成奴才砰郭啸天桌上重重拍一记震倒一只酒杯酒水流满桌怒道不要脸不要脸这鸟皇帝算是一门子皇帝张。

可以看出二者生成的文本都有一定的逻辑性和通顺性,理论上来讲 Transformer 的性能 应该更优,但由于我使用的 Transformer 规模比较小,语料库也比较小,可能没能发挥出 Transformer 真正的优势,而且 Transformer 训练时的 batchsize 仅仅为 16 而 Seq2Seq 训练时的 batchsize 为 1024,可以认为 Transformer 收敛的没有 Seq2Seq 好(16 已经是极限了,再大就爆显存了),被算力原因限制了。

结果分析与结论

本实验以《射雕英雄传》为语料库分别采用 Seq2Seq 和 Transformer 两种语言模型训练了文本生成模型,从结果上来讲实验没能看出二者在性能上具有明显差异,可能是由于 Transformer 在小模型和小数据的条件下并不能发挥其优势,但在实验过程中学习了两种模型的理论知识,还是较为深刻地了解了两种模型在理论上的优缺点。